



Proyecto 1 — Agencia Metropolitana de Transporte

Fase 1 — Desglose de la arquitectura

José Carlos Avalos - 1315918

Guatemala, 23 de septiembre del 2026

Tabla de contenido

- 1. RESUMEN..... 3
- 2. ARQUITECTURA DE LA SOLUCIÓN..... 4
- 3. 1.1 INGESTA Y CAPA BRONZE..... 4
- 4. 1.2 STAGING Y CDC..... 5
- 5. 1.3 CAPA SILVER..... 6
 - 5.1 ESTRATEGIA DE IDENTIDAD..... 6
 - 5.2 CALIDAD Y CUARENTENA..... 6
 - 5.3 SCD TIPO 2 6
- 6. 1.4 MODELO DIMENSIONAL Y GOLD 7
 - 6.1 GRANO DE LOS HECHOS..... 7
 - 6.2 MATRIZ DEL BUS..... 7
 - 6.3 MEDIDAS..... 8
 - 6.4 RESULTADOS GOLD 8
- 7. 1.5 ORQUESTACIÓN E IDEMPOTENCIA 9
- 8. RESULTADOS Y MÉTRICAS..... 10
- 9. SEGURIDAD, REPRODUCIBILIDAD Y LINAJE 11
- 10. CONCLUSIONES..... 12

1. Resumen

La Fase 1 implementa una arquitectura de datos para integrar cuatro operadores de transporte con estructuras heterogéneas: Transmetro, Transurbano, MetroRiel y Aerómetro, además del padrón de usuarios procesado como CDC. La solución combina ingesta streaming con Kafka, cargas batch, procesamiento de cambios, una capa Bronze de preservación, Staging transitorio, Silver para normalización y calidad, y Gold con un modelo dimensional.

El pipeline fue ejecutado y validado con dbt, DuckDB y Prefect. Las pruebas de dbt finalizaron sin errores y la prueba de idempotencia confirmó conteos idénticos en dos corridas consecutivas. Los registros que incumplen reglas de calidad no se descartan: se preservan en cuarentena con el motivo correspondiente.

Arquitectura lógica de la Fase 1




Figura 1. Arquitectura lógica implementada para la Fase 1.

2. Arquitectura de la solución

La arquitectura sigue el patrón Bronze–Silver–Gold y mantiene una separación explícita entre almacenamiento crudo, transformación y consumo analítico. Gold no lee Bronze directamente; las tablas finales dependen de modelos Silver, lo que mantiene trazabilidad y evita saltarse reglas de calidad.

Componente	Tecnología / enfoque	Propósito
Streaming	Kafka en Docker	Simular llegada de eventos de Transmetro y Aerómetro.
Batch	Python / archivos fuente	Cargar catálogos, Transurbano y MetroRiel.
CDC	Archivo cdc_padron_usuarios.csv	Aplicar INSERT, UPDATE y DELETE lógico por secuencia.
Bronze	Lake local particionado por fecha	Conservar el dato crudo y registrar ingesta.
Staging	Modelos dbt transitorios/ephemeral	Preparar lectura sin persistencia innecesaria.
Silver	dbt + DuckDB	Normalizar, conformar, controlar calidad y aplicar SCD2.
Gold	Modelo dimensional dbt	Exponer hechos y dimensiones para analítica.
Orquestación	Prefect	Ejecutar y validar el flujo técnico.

3. 1.1 Ingesta y capa Bronze

Transmetro y Aerómetro se procesan como streaming mediante Kafka. Los catálogos de estaciones/paradas, Transurbano y MetroRiel se procesan por batch. El patrón de usuarios se trata como CDC. Para Transurbano se eligió batch porque el insumo recibido es un archivo cerrado de transacciones y no representa una fuente evento-a-evento, la principal consecuencia es mayor latencia respecto de streaming, a cambio de una carga reproducible y coherente con el archivo entregado.

Bronze se implementa como un lake local particionado por fecha. Los datos se conservan sin transformar y se registra información de ingesta. Para los archivos batch/CDC se usa un manifiesto con hash para evitar reingresar el mismo archivo en una segunda ejecución, para Kafka se preserva la posición topic/partition/offset para no eliminar duplicados de negocio válidos por accidente.

Archivo	Filas medidas	Vía de ingesta
tm_estaciones.csv	104	Batch
tu_paradas.csv	328	Batch
mr_estaciones.csv	22	Batch
am_estaciones.csv	14	Batch
transmetro_validaciones.csv	363,221	Kafka
transurbano_transacciones.csv	832,791	Batch
metroriel_viajes.jsonl	299,100	Batch
aerometro_boardings.csv	203,554	Kafka
cdc_padron_usuarios.csv	31,050	CDC

4. 1.2 Staging y CDC

Staging se mantiene como una capa transitoria de lectura y tipado. El CDC del padrón se procesa respetando la secuencia del evento. Los DELETE no eliminan físicamente al usuario: generan una versión inactiva, manteniendo historial.

Métrica CDC	Resultado
INSERT	10,800
UPDATE	16,200
DELETE	4,050
Llaves distintas observadas	22,463
Estado final activo	19,469
Estado final inactivo	2,994
Eventos SIN-TARJETA	2,206

Se generaron catálogos mínimos de llaves distintas para los operadores solicitados, sin inventar datos ni relaciones inexistentes:

Operador	Usuarios/llaves únicas
Transurbano	36,567
MetroRiel	22,885
Aerómetro	14,496

```

(.venv) joseavalos@MacBook-Ekko Proyecto1_Fase1_Final % python scripts/08_catalogos_usuarios.py

CATALOGOS MINIMOS GENERADOS CORRECTAMENTE

operador usuarios_unicos
Transurbano 36567
MetroRiel 22885
Aerometro 14496

Archivos creados:
- data/outputs/usuarios_transurbano.csv
- data/outputs/usuarios_metroriel.csv
- data/outputs/usuarios_aerometro.csv
- data/outputs/usuarios_unicos_resumen.csv

```

Figura 2. Generación de catálogos mínimos de usuarios.

5. 1.3 Capa Silver

Silver normaliza timestamps, moneda, zonas, identificadores y reglas de calidad. Transurbano convierte monto_centavos a quetzales, Aerómetro transforma UTC a hora local de Guatemala, MetroRiel aplanar su estructura de viaje, y se conforman nombres de zonas y puntos de transporte.

5.1 Estrategia de identidad

Para Transmetro, Transurbano y MetroRiel se usa como aproximación el componente numérico de la llave para construir un candidato canónico común. Aerómetro conserva una identidad separada AM:<hash>, ya que el archivo no provee una tabla de correspondencia con los demás sistemas. La identidad usada en Gold se seudonimiza con SHA-256 y una sal de entorno.

5.2 Calidad y cuarentena

Regla	Registros medidos	Tratamiento
Duplicado Transmetro por validacion_id	1,115	Cuarentena: duplicado_evento
Transurbano sin cod_parada	4,189	Cuarentena: parada_nula
Transurbano con fecha futura	817	Cuarentena: fecha_futura
MetroRiel sin salida	3,589	Cuarentena: viaje_sin_salida

La cuarentena total contiene 9,707 registros. El total no es la suma directa de las cuatro reglas porque tres registros de Transurbano cumplen simultáneamente parada nula y fecha futura.

5.3 SCD Tipo 2

El modelo silver_padron_scd2 conserva una versión por evento CDC. valido_desde corresponde al commit_ts; valido_hasta se obtiene a partir del siguiente cambio de la misma llave; es_actual identifica la versión abierta; y activo es falso cuando la operación es DELETE. De esta forma se conserva el historial sin borrado físico.

6. 1.4 Modelo dimensional y Gold

Se utilizan dos hechos porque los eventos de Transmetro, Transurbano y Aerómetro representan abordajes/validaciones, mientras MetroRiel entrega viajes con origen y destino en una misma observación. Mantener dos granos evita perder información o introducir inferencias no sustentadas por los datos.

Modelo dimensional propuesto para Gold




Figura 3. Modelo dimensional de Gold.

6.1 Grano de los hechos

Tabla de hechos	Grano
fact_abordaje	Una fila por abordaje/validación exitosa de TM, TU o Aerómetro para usuario, punto y momento.
fact_viaje_metroriel	Una fila por viaje completo de MetroRiel con origen, destino y tiempos asociados.

6.2 Matriz del bus

Proceso / Hecho	DimUsuario	DimTiempo	DimZona	DimModo	DimEstacionParada	DimRuta
FactAbordaje	X	X	X	X	X	X
FactViajeMetroRiel	X	X	X	X	X	—

6.3 Medidas

Medida	Clasificación	Justificación
conteo_abordaje	Aditiva	Puede sumarse a través de todas las dimensiones.
conteo_viaje	Aditiva	Puede sumarse a través de todas las dimensiones.
monto_q	Aditiva	Los cobros se pueden acumular por dimensiones.
usuarios_distintos	No aditiva	COUNT DISTINCT no se suma entre particiones.
tarifa_promedio	No aditiva	Los promedios no se suman directamente.
Saldo/snapshot	Semi-aditiva — no implementada	La fuente no contiene saldo/snapshot; no se inventa una medida.

6.4 Resultados Gold

Objeto	Conteo final
fact_abordaje	1,352,058
fact_viaje_metroriel	295,511




Figura 4. Linaje dbt de fact_abordaje.

7. 1.5 Orquestación e idempotencia

Prefect orquesta la inspección de fuentes, verificación de Bronze, ejecución de dbt, pruebas y validación de conteos. La corrida observada finalizó en estado Completed. dbt construyó 15 modelos sin errores y ejecutó 8 pruebas de datos con resultado PASS.

Validación	Resultado
dbt run	PASS=15, ERROR=0
dbt test	PASS=8, ERROR=0
Prefect flow	Completed

```
(.venv) joseavalos@MacBook-Ekko Proyecto1_Fase1_Final % python scripts/07_prefect_flow.py
01:39:01
01:39:01 Finished running 15 table models in 0 hours 0 minutes and 1.76 seconds (1.76s).
01:39:01
01:39:01 Completed successfully
01:39:01
01:39:01 Done. PASS=15 WARN=0 ERROR=0 SKIP=0 NO-OP=0 REUSED=0 TOTAL=15
19:39:02.946 | INFO | Task run 'cmd-e0c' - Finished in state Completed()
01:39:03 Running with dbt=1.12.5
01:39:03 Registered adapter: duckdb=1.11.0
01:39:04 Found 24 models, 8 data tests, 500 macros
01:39:04
01:39:04 Concurrency: 4 threads (target='dev')
01:39:04
01:39:04 2 of 8 START test not_null_dim_usuario_usuario_pseudo ..... [RUN]
01:39:04 1 of 8 START test not_null_dim_estacion_parada_estacion_parada_sk ..... [RUN]
01:39:04 4 of 8 START test not_null_fact_viaje_metroriel_viaje_uid ..... [RUN]
01:39:04 3 of 8 START test not_null_fact_abordaje_evento_uid ..... [RUN]
01:39:04 2 of 8 PASS not_null_dim_usuario_usuario_pseudo ..... [PASS in 0.03s]
01:39:04 5 of 8 START test unique_dim_estacion_parada_estacion_parada_sk ..... [RUN]
01:39:04 1 of 8 PASS not_null_dim_estacion_parada_estacion_parada_sk ..... [PASS in 0.04s]
01:39:04 3 of 8 PASS not_null_fact_abordaje_evento_uid ..... [PASS in 0.03s]
01:39:04 6 of 8 START test unique_dim_usuario_usuario_pseudo ..... [RUN]
01:39:04 4 of 8 PASS not_null_fact_viaje_metroriel_viaje_uid ..... [PASS in 0.03s]
01:39:04 7 of 8 START test unique_fact_abordaje_evento_uid ..... [RUN]
01:39:04 8 of 8 START test unique_fact_viaje_metroriel_viaje_uid ..... [RUN]
01:39:04 5 of 8 PASS unique_dim_estacion_parada_estacion_parada_sk ..... [PASS in 0.02s]
01:39:04 6 of 8 PASS unique_dim_usuario_usuario_pseudo ..... [PASS in 0.03s]
01:39:04 8 of 8 PASS unique_fact_viaje_metroriel_viaje_uid ..... [PASS in 0.03s]
01:39:04 7 of 8 PASS unique_fact_abordaje_evento_uid ..... [PASS in 0.05s]
01:39:04
01:39:04 Finished running 8 data tests in 0 hours 0 minutes and 0.14 seconds (0.14s).
01:39:04
01:39:04 Completed successfully
01:39:04
01:39:04 Done. PASS=8 WARN=0 ERROR=0 SKIP=0 NO-OP=0 REUSED=0 TOTAL=8
19:39:04.779 | INFO | Task run 'cmd-756' - Finished in state Completed()
    objeto conteo
    silver_tm 363221
    silver_tu 832791
    silver_mr 299100
    silver_am 203554
    gold_fact_abordaje 1352058
    gold_fact_metroriel 295511
    cuarentena 9707
19:39:05.103 | INFO | Task run 'cmd-427' - Finished in state Completed()
19:39:06.039 | INFO | Flow run 'inescapable-vulture' - Finished in state Completed()
19:39:06.733 | INFO | prefect - Stopping temporary server on http://127.0.0.1:8574
```

Figura 5. Ejecución orquestada con Prefect, dbt y validación final.

La idempotencia se comprobó ejecutando el procesamiento dos veces y comparando los conteos. Las dos corridas devolvieron exactamente los mismos valores en Silver, Gold y cuarentena.

Objeto	Corrida 1	Corrida 2
silver_tm	363,221	363,221
silver_tu	832,791	832,791
silver_mr	299,100	299,100
silver_am	203,554	203,554
gold_fact_abordaje	1,352,058	1,352,058
gold_fact_metroriel	295,511	295,511
cuarentena	9,707	9,707

```
Salida  Terminal  Problemas

(.venv) joseavalos@MacBook-Ekko Proyecto1_Fase1_Final % python scripts/06_prueba_idempotencia.py
gold_fact_metroriel 295511
cuarentena 9707
IDEMPOTENCIA: OK - CONTEOS IDÉNTICOS
      objeto  conteo  corrida
      silver_tm 363221      1
      silver_tu 832791      1
      silver_mr 299100      1
      silver_am 203554      1
gold_fact_abordaje 1352058      1
gold_fact_metroriel 295511      1
cuarentena 9707      1
      silver_tm 363221      2
      silver_tu 832791      2
      silver_mr 299100      2
      silver_am 203554      2
gold_fact_abordaje 1352058      2
gold_fact_metroriel 295511      2
cuarentena 9707      2
❏ (.venv) joseavalos@MacBook-Ekko Proyecto1_Fase1_Final %
```

Figura 6. Evidencia de idempotencia con conteos idénticos.

8. Resultados y métricas

Capa / métrica	Resultado
Silver Transmetro	363,221
Silver Transurbano	832,791
Silver MetroRiel	299,100
Silver Aerómetro	203,554
Gold FactAbordaje	1,352,058

Gold FactViajeMetroRiel	295,511
Cuarentena	9,707
Pruebas dbt	8 PASS
Modelos dbt	15 PASS

Estos valores sirven como línea base para la defensa, la demostración de idempotencia y la revisión de consistencia entre las capas.

9. Seguridad, reproducibilidad y linaje

- Gold utiliza una identidad seudonimizada en lugar de exponer las llaves originales de usuario.
- Los secretos y la sal deben administrarse como variables de entorno y no versionarse.
- Bronze conserva los datos recibidos y sus metadatos de ingesta; Silver aplica reglas explícitas y cuarentena.
- El linaje dbt permite rastrear modelos Gold hacia Silver y modelos de auditoría hacia las fuentes transformadas.
- La ejecución se reproduce mediante scripts, dbt y Prefect; los conteos de referencia están documentados.




Figura 7. Linaje dbt de la tabla de cuarentena.

10. Conclusiones

Se implementó un pipeline reproducible que separa la preservación del dato, la transformación de calidad y el consumo analítico. La solución conserva los errores en cuarentena, mantiene el historial CDC mediante SCD Tipo 2 y evita dependencias directas de Gold hacia Bronze.

Los conteos finales, las pruebas dbt, el linaje y la ejecución de Prefect aportan evidencia verificable del funcionamiento. La idempotencia fue comprobada con dos corridas idénticas, lo cual reduce el riesgo de duplicados al reejecutar el procesamiento.